

引用格式: 马毓哲,王蒙,李辉等. RUG: 收益驱动的单向共享汽车用户重定位模型[J]. 地球信息科学学报,2023,25(12):2315-2328. [Ma Y Z, Wang M, Li H, et al. RUG: A revenue-driven user-based relocation approach in one-way car-sharing incorporating public transportation[J]. Journal of Geo-information Science, 2023,25(12):2315-2328.] DOI:10.12082/dqxxkx.2023.230280

RUG :收益驱动的单向共享汽车用户重定位模型

马毓哲¹,王 蒙^{1,2*},李 辉^{3,4},崔江涛³,刘俊华^{1,2},李瑞蒙¹

1. 西安工程大学计算机科学学院,西安 710048; 2. 陕西省服装设计智能化重点实验室,西安 710048; 3. 西安电子科技大学计算机科学与技术学院/西安市先进数据库技术重点实验室,西安 710126; 4. 上海沄熹科技有限公司,上海 200131

RUG: A Revenue-driven User-based Relocation Approach in One-way Car-sharing Incorporating Public Transportation

MA Yuzhe¹, WANG Meng^{1,2*}, LI Hui^{3,4}, CUI Jiangtao³, LIU Junhua^{1,2}, LI Ruimeng¹

1. School of Computer Science, Xi'an Polytechnic University, Xi'an 710048, China; 2. The Shaanxi Key Laboratory of Clothing Intelligence, Xi'an 710048, China; 3. School of Computer Science and Technology, Xidian University / The Xi'an Key Laboratory of Advanced Database Technology, Xi'an 710126, China; 4. Shanghai Yunxi Technology Co., Ltd., Shanghai 200131, China

Abstract: Car-sharing services can meet the diverse travel needs of users while helping to alleviate traffic congestion and reduce pollution. In many scenarios, car-sharing is more economical than taxis. One-way car-sharing allows users to rent and return cars at any station within the system, which leads to low operating costs and flexible services. However, the spatiotemporal skewness of user travel demand gives rise to imbalances between vehicle supply and demand among stations, which limits the profitability of car-sharing companies. Relocating vehicles can alleviate the above problems to some extent. Most existing studies construct optimization models with the goal of maximizing expected revenue or reducing system imbalance. The former is limited by the insufficient accuracy of travel demand prediction, and the mode of discarding definite orders and pursuing higher possible expected benefits instead cannot guarantee actual profits. To improve system balance, the latter pays more relocation costs such that reduces the profitability. To this end, we propose a revenue-driven one-way car-sharing user relocation model RUG that is suitable for real-time scenarios. The model is based on the deterministic effect of prospect theory, which ensures the current definite gains. For orders that cannot be fulfilled due to imbalanced resources, RUG provides users with alternative travel routes, which not only attempts for promising gains but also effectively balances the system. Users are incorporated into the system as relocation subjects by designing rational user incentive and acceptance models. Public transportation is utilized to break through the distance limitations of user relocation. Relocation plans are evaluated with a greedy heuristic. Experimental results on real-world New York datasets show that the RUG model has significant advantages over existing user-based relo-

收稿日期 2023-04-10;修回日期 2023-09-07.

基金项目:国家自然科学基金项目(61976168,61972309,62272369);陕西省自然科学基础研究计划资助项目(2023-JC-YB-558)。

[**Foundation items:** National Natural Science Foundation of China, No.61976168, 61972309, 62272369; Natural Science Basic Research Program of Shaanxi, No.2023-JC-YB-558.]

作者简介:马毓哲(1997—),男,河南平顶山人,硕士生,主要研究方向为时空大数据。E-mail: a17603869707@163.com

*通讯作者:王 蒙(1981—),男,陕西西安人,博士,副教授,硕士生导师,主要研究方向为时空大数据、数据管理和数据挖掘。E-mail: wangmeng@xpu.edu.cn

tion methods. Under the same parameters, compared to the representative user-based relocation method, RUG increases service order volume and profit by 14% and 60%, respectively. Notably, RUG can effectively raise unit profits during traffic rush hours. By incorporating travel demand forecasting, the model further increases revenue by 5.4% while also improving user service level and system balance.

Key words: one-way car-sharing; revenue driven; prospect theory; user-based relocation; user incentives; greedy heuristic; public transportation; travel demand forecast

*Corrsponding author: WANG Meng, E-mail: wangmeng@xpu.edu.cn

摘要 共享汽车在满足用户多样化出行需求的同时,有助缓解交通拥堵、降低污染,很多场景比出租车更为经济。单向共享汽车允许用户在系统内任意站点借车和还车,具备运营成本低、服务灵活的优势。然而,用户出行需求的时空偏态性会导致站点间车辆和需求不平衡,成为制约单向共享汽车企业盈利的关键问题。车辆调度能在一定程度上缓解上述问题,现有研究多数以期望收益最大化或降低系统不平衡性为目标构建优化模型。前者受限于出行需求预测精度不足,放弃当前订单而追求期望更高收入的模式难以保证实际收益;后者为满足系统平衡而付出更多调度成本会使系统盈利能力下降。为此,本文提出一种收益驱动并适用实时场景的单向共享汽车用户重定位模型RUG,基于前景理论的确定效应保证当前可获得收益,对于受系统资源限制无法满足的需求,通过为用户提供替代方案在尝试获取收益的同时,也能有效平衡系统车辆资源。通过设计合理的用户激励和接受度模型将用户作为重定位主体纳入系统,利用公共交通突破传统用户重定位车辆的距离局限,以贪心的最优化实现调度计算。在真实的纽约出行和共享汽车数据集上的实验结果表明,RUG模型相比现有用户重定位方法优势显著,在同样模型参数条件下,相比现有代表性基于用户调度方法,RUG在服务订单数和利润2个方面分别提高14%和60%,尤其提升了交通高峰期单位利润。通过加入出行需求预测,模型进一步增加5.4%收益的同时,还能有效改善用户服务水平和系统平衡性。

关键词 单向共享汽车;收益驱动;前景理论;用户重定位;用户激励;启发式贪心;公共交通;出行需求预测

1 引言

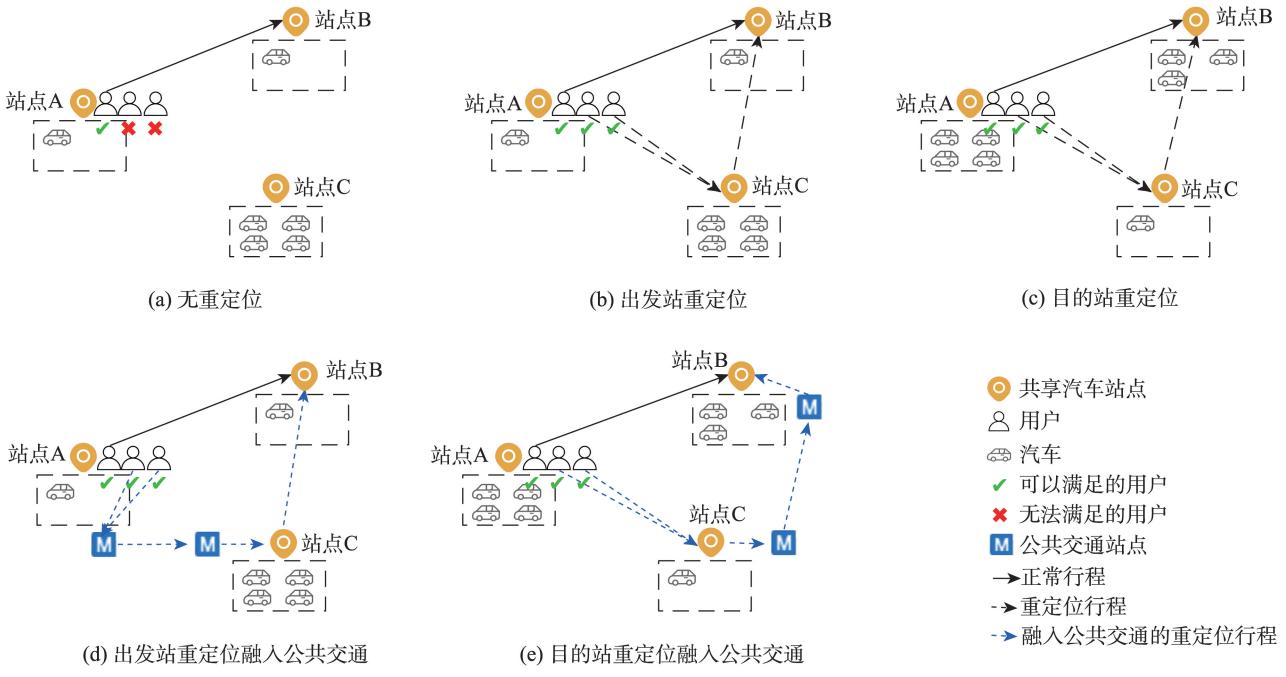
共享经济是依托移动互联网和数字化生活方式发展起来的新型业态,其减少资源闲置、提高资源利用率的特性也成功推动了交通领域共享汽车的发展。作为城市交通新模式,共享汽车的出现不仅满足用户多样化出行需求,也有助缓解交通拥堵、降低污染^[1]、提升社会效益^[2],很多场景比出租车更为经济^[3]。

共享汽车分为自由浮动型和基于站点型2类^[4]。前者用户可在运营区域内任何位置归还车辆,这种高自由度会导致运营成本高昂,故并不常见。后者要求用户到运营商指定站点借还车辆,且分为往返型和单向型2种模式。往返型中,用户必须将车辆归还至原借车站点,此模式服务灵活性差,无法满足普遍的单向出行需求。基于站点的单向型共享汽车(简称单向共享汽车)并不强制用户将车辆归还至原出发站,用户可在系统内任意站点还车。此模式更为灵活,但运营商需承担较高的运营成本。

单向共享汽车面临的最大挑战是用户出行需求的时空偏态性,其会导致需求旺盛区域站点缺乏

可用车辆,用户订单无法满足,而需求冷门区域则相反,站内车辆长时间闲置。如不通过重定位(也称调度,将站内闲置车辆搬到车辆稀缺站)加以干预,必然影响服务水平和收益,甚至导致亏损。图1(a)、图1(b)和图1(c)展示有/无用户重定位的服务水平差异。

鉴于需求偏态的负面性,学者们提出多种策略试图通过提高预期收入或降低重定位成本提高运营效益。这些方案从不同理论角度设计了解决路径,但仍存在局限:①基于优化和仿真的方法假定用户需求已知,即系统仅支持预约订单^[5],但优化调度会舍弃一些预约用户,该“预约-舍弃”矛盾必然造成用户体验糟糕;②根据未来几小时窗口期的预约或历史需求规划重定位^[5]且假定调度无需时间,其较长的窗口期难以应对实时场景;③结合需求预测^[6-8]尽可能不损失用户或预期收益最大,但由于预测准确度有限,放弃当前订单而选择未来更佳的可能收益,难以保证实际利润一定提高(见3.1节);④现有基于用户重定位方法约束用户调度距离小于500 m^[8],但单向共享汽车站点间多大于该距离,实际能满足条件屈指可数。



注: 图(a)表示A站的3个用户出行需求由于缺乏可用车辆只能满足一人;图(b)表示另外2个无法满足的用户从邻近且车辆充足的C站驾驶车辆前往目的地;图(c)表示3个从A站到B站的出行需求由于目的地B站缺乏停车位,只能满足一个需求,另外2个无法满足需求的用户可驾车从A抵达C站后,步行或使用其他交通工具前往目的地B;图(d)和图(e)分别为在图(b)和图(c)的用户重定位基础上加入公共交通元素。

图1 重定位单向共享汽车各模式

Fig. 1 The examples of relocation modes for one-way car-sharing

上述局限导致现实中共享汽车运营收益并不理想。为此,本文依据前景理论^[9],从保证确定性获利规避风险角度出发,避免遵循期望最大化原则时需求预测精度不足的客观缺陷(见3.1节),将模型聚焦于提升确定收益,而非从期望最大收益寻求最小损失,毕竟实际运营企业不可能提供满足所有需求的资源。此外,本文考虑用户激励策略和用户接受度模型,将公交系统融入用户重定位,突破站点间用户调度距离限制,基于前景理论的保证收益规避风险原则,利用贪心局部最优化构建适用实时场景的用户调度模型RUG(Revenue-driven User-based Greedy relocation)。为验证RUG的有效性,在真实出行需求数据,及共享汽车、停车位和公交系统价格数据上进行仿真实验。与现有代表性基于用户和基于运营商重定位方法^[6,10]相比,RUG模型在相同条件下订单数和利润提升明显,相比加入公交系统后文献[6]的用户调度模型也能提高14%和60%,体现显著的优越性。结合CSTN(Contextualized Spatial-Temporal Network)^[11]预测未来半小时站点附近出行需求,模型在提升5.4%收益的同时也能有效改善用户服务水平和系统平衡性。

2 相关研究

共享汽车研究分为战略规划和战术运营^[12],前者是在建设共享汽车系统前,规划站点数量、容量、位置和车辆配额等;后者是在系统建成投入运营后,通过重定位解决车辆失衡问题。本文属于单向共享汽车战术运营问题,下面分别讨论由运营商雇佣员工执行调度,和通过运营商给予用户折扣、免费驾驶时间等激励^[13-14],促使用户改变出发站或目的站从而达成调度。

2.1 基于运营商重定位

Kek等^[15]提出基于耗时最短和从车辆最多站点搬移到最缺车辆站点2种调度,并进一步构建了三阶段优化趋势模拟的近似最优重定位策略^[16],但研究均注重提高调度效率而非收益。Nair等^[5]设计基于混合整数线性规划的方案,严苛假定用户需求预先可知,且为满足优化算法的可解性引入虚拟车辆和车位,使方法更偏向理论而非实际。Brendel等^[17]基于应用经济物理学设计系统能量重定位算法,将服务区域划分为网格并计算每个网格的车辆能量

值,当网格满足能量阈值时用户“无偿同意”重定位,但该假设显然过于理想化。Repoux 等^[10]改进文献[15]提出的方法,设计的OVOS模型在法国共享汽车数据集实验表明,相比其他方法,OVOS在服务水平和收入方面均具备优势。Kypriadis 等^[18]提出针对自由浮动型共享汽车的重定位方法,但该算法没有考虑停车位费用且每天夜间执行一次调度策略很难应对用户的实时出行需求。与文献[5]类似,Gambella 等^[19]研究的电动汽车共享系统也假设基于预约,尽管其整形规划模型细致地考虑了车辆电池消耗和充电过程,但以系统最佳为优化方向会拒绝部分已预约用户而影响体验。为降低系统运营成本和调度员的不平衡度,Yang 等^[20]设计了一种基于站间距离的搬迁弧模型,将滚动地平线算法与分解优化相结合,能解决较细粒度下优化的计算性能问题。

2.2 基于用户重定位

用户重定位方案^[21-22]基于自动浮动型共享汽车。Wagner 等^[21]采用与文献[17]类似的网格模式,选择接受概率最大的网格为重定位目标,区别在于采用额外驾驶距离与接受概率的负相关用户激励策略,但该方法难以体现交通高峰期的行驶时间差异(5.2.2 节实验显示了不同时段确实存在影响)。Schulte 等^[22]的方案尝试提供多种用户重定位策略,但并未给出激励和接受概率公式,仅能进行定性分析。自由浮动共享汽车的优势在于可任意停放车辆,但这些方案无法直接适用基于有限站点的共享汽车^[21],且上述研究并未考虑路边停车价格和是否允许停放问题,还面临车辆频繁充电、需求可预测性差等缺陷^[23]。

Brendel 等^[6]基于需求预测并以维持系统平衡为目标,然而该策略并不能很好地保证收益(见5.2.1节)。此外,其用户激励未考虑参与调度产生的额外时间,也不符合前景理论中人们的参照依赖原理^[9]。Wang 等^[7]和 Stokkink 等^[8]均结合预约订单和需求预测构建模型,根据预期收益最大化来规划调度,即以当前部分重定位收入为代价以期避免未来的总体损失。由于预测精度有限,放弃当前确定订单很难保证实际收益一定提高。文献[8]还尝试结合公交系统,但 500 m 用户重定位距离约束和无公交费用补偿导致效果不佳。最近 Wang 等^[24]提出了更为复杂的模型,综合考虑了用户重定位和运营

商调度,并在调度路径中加入共享单车。该模型中运营商调度带来的负面成本(5.2.1节实验说明运营商调度成本不可忽视)、用户是否接受共享单车行程(如雨雪等恶劣天气、是否有自行车可用等),以及系统为参与搬迁的用户提供固定折扣稍显不合理,都限制了该研究的应用场景。

3 基础理论及依赖模型

本章首先论述研究采用前景理论的出发点,然后提出本文设计模型中用户重定位所依赖的用户激励和接受度模型。

3.1 前景理论

前景理论(Prospect Theory)^[9]是行为经济学中描述人们在面对风险和不确定性时决策行为的理论,包括人们如何衡量风险和回报,并在此基础上做出选择。前景理论包括4个基本结论^[25]:

(1)确定效应:处于收益状态的人们做出决策时,更愿意选择保守选项。例如,当面对 50% 的机会获得 100 元和获得 50 元的确定回报时,更倾向于选择后者。

(2)反射效应:当人们面对损失状态时,更倾向于采取冒险的策略,以期望损失减小或消失。例如,当面对 50% 的机会不损失 100 元和确定损失 50 元时,更倾向于选择前者。

(3)损失规避:人们对于损失比收益更敏感,因此倾向于采取措施来避免损失,即使这些措施可能会导致更小的回报。

(4)参照依赖:人们的得失判断往往受到参考点的影响。具体来说,人们更关注相对于参考点的得失,而非绝对得失。例如,面对 2 个选项,一个是 50% 的机会获得 100 元,另一个是 50% 的机会失去 50 元时,大多数人更倾向于前者,因为相对于参考点(通常是人们拥有的财富或期望获得的回报),前者的回报更高。

简而言之,前景理论揭示处于收益状态时,人们通常是风险厌恶的,即保守选择更确定的回报;而面对损失时,通常会采用措施尝试减小损失。而对于得失,人们关注于参考点的相对回报。

目前多数重定位策略基于期望最大化,通过牺牲系统当前一些无需调度即可满足的订单,而期望提高未来系统可能获取的总体收益,但需要承担收

益损失风险。但由于预测准确度有限,放弃当前订单而选择未来更佳的可能收益,难以保证实际利润一定提高,例如第5节真实出行数据集中,所有行程费用的中位数为\$12.4 (\$0.4/km 标准),所有行程中收益最高的三分之一行程的平均值为\$13.8,这意味着如果基于期望最大化制定重定位策略,放弃当前一个中位数订单以期满足未来一个收益可能更高的订单,未来半小时可能损失收益为: 中位数订单收益×预测平均绝对误差(MAE)= $12.4 \times 0.53 \approx \6.6 (预测需求的 MAE 为 0.53, 见 4.4 节), 在假定用户全同意调度的理想情况下, 最糟需要 $[6.6 \div (13.8 - 12.4)] = 5$ 次最高费用订单才能弥补之前放弃的收益。预测方法的精度偏差,使得从理论最大收益出发寻求预期损失最小策略难以避免上述风险。故本文选择更符合实际的前景理论确定效应,聚焦保证确定性收益。

3.2 激励计算

用户通常愿意花费额外时间以获得折扣^[10]。借鉴研究^[6]的激励模型,本文同样基于用户花费额外时间作为提供激励的依据,但不同之处在于,计算激励并非设置单位时间激励,而是以调度花费额外时间占原行程时间比例给予折扣,如式(1),值得注意的是,用户接受系统提供的重定位建议后,为用户行程减免的费用不会大于原行程费用。这样设计用户激励也更符合前景理论中用户选择的参照依赖^[9],即人们的得失判断受参照点的影响。举例来说,如原行程 40 min 和 30 min,若需要额外花费 10 min 重定位,由于用户心理参考点(即 40 min 和 30 min)完全不同,为获得相近的激励效果,需要放大原行程时间较短参照点用户的激励。因此,按本文提出激励公式(1),分别为不同参照点用户提供 1/4 和 1/3 折扣。

$$\varepsilon = r_j^i \times \frac{\Delta t}{t_j^i} \quad (1)$$

式中: ε 为用户接受系统提供的重定位建议后; r_j^i 为用户从车站 i 到车站 j 原行程租金; t_j^i 为用户原本行程花费时间; Δt 为由于用户调度额外花费时间。

3.3 用户接受调度概率

基于用户的重定位不能忽视用户接受度的随机性^[21],以往的研究中针对用户接受概率模型,有 2 种构建思路。^① 典型策略是定义为重定位行程

与原行程距离关系的线性关系^[21],用模型 $\rho_{ih} = 1 - \frac{dist(t_i, t_h)}{\sigma}$ 表征接受从给定位置 t_i 重定位到 t_h 的概率,其中 $dist(t_i, t_h)$ 和 σ 分别表示重定位的额外距离和原行程距离。然而,这种线性关系并不符合用户对距离的非线性(负指数)偏好^[26]。^② 策略考虑了非线性的用户偏好分布特点,如文献[8]构建了模型 $P_{acc}(X) = \frac{1}{1 + e^{-(\beta X)}}$, 其中接受概率 $P_{acc}(X)$ 由重定位引起的额外行程 X 和不同用户的代价权值 β 决定,每个用户的单位距离或时间价值 β 因人而异。出于避免“大数据杀熟”原则考虑,本文提出的接受概率模型对每个用户一视同仁,即假定 $\beta=1$ 。此外,考虑到相同路程在交通高峰期和非高峰期时段行驶时间差异,现有多数策略简单地将距离作为判断用户接受度的基准仍是不完善的。基于上述因素考虑,本文采用额外行程时间衡量用户代价,参照文献[26]负指数函数构建了非线性公式(2)来计算基于额外代价与原行程时间关系的新颖接受概率模型。接受概率与时间比值的关系如图 2 所示,并通过约束用户额外时间与原行程时间比值小于 1 ($\Delta t/t_j^i < 1$) 来保证收益,即系统拒绝执行负利润的用户重定位操作。

$$p = \frac{1}{e^{(\Delta t/t_j^i)}} - \frac{1}{e} \quad (2)$$

式中: Δt 为重定位行程相较原行程的额外花费时间; t_j^i 为用户原本行程从出发站 i 到目的站 j 所花费的时间; e 为自然常数; p 为用户接受系统重定位建议的概率。

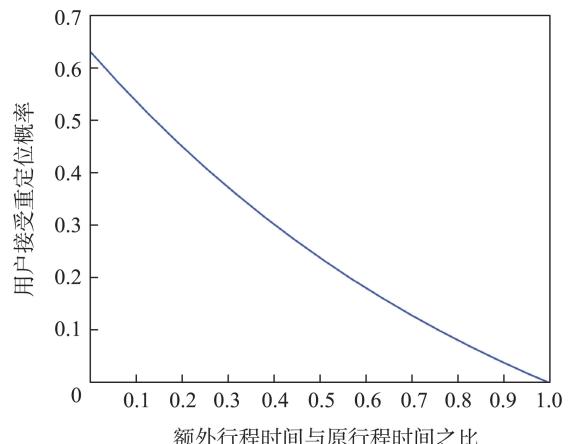


图 2 基于代价 $\Delta t/t_j^i$ 的接受概率

Fig. 2 Acceptance probability based on cost $\Delta t/t_j^i$

4 RUG模型

本节阐述图3所示的收益驱动单向共享汽车用户重定位模型RUG,详细讨论模型中订单类型划分方法、融入公交系统方式、收益驱动的贪心局部最优调度,以及结合预测的优化。

4.1 订单分类及划分方法

基于用户的重定位是在单向共享汽车系统中车辆或车位无法满足需求时,系统建议用户使用替代站点资源实现出行。RUG模型将所有可满足的用户订单分为3类:

(1)普通订单。式(3)和式(4)约束用户出发站和目的站分别有可用车辆及车位,即无需重定位,需要说明的是,用户一旦从站 o 车出发,系统将在站 d 留车位直至用户抵达并归还车辆。式(5)表示普通订单收入 i 的计算方式,需要考虑用户支付租金 r_d^o 和车辆行驶成本 $l_d^o \times loss$ 。

$$n_v^o - n_{rv}^o > 0 \quad (3)$$

式中: n_v^o 为用户出发站现有车辆数; n_{rv}^o 为系统已生成的行程在站点 o 的预约车辆数。

$$n_p^d - n_{rp}^d > 0 \quad (4)$$

式中: n_p^d 为用户目的站车位数; n_{rp}^d 为系统为已生

成行程在站点 d 保留的车位数。

$$i = r_d^o - l_d^o \times loss \quad (5)$$

式中: r_d^o 为用户行程租金; l_d^o 为用户行程距离; $loss$ 为车辆行驶每公里的能耗和折旧成本; i 为普通订单收入。

(2)出发站重定位(Origin Relocation, OR)订单。当出发站无可用车辆但目的站有可用车位,即满足式(6)和式(7)时可执行出发站重定位,其中式(6)评估用户出发站车辆数 n_v^o 与其他用户在该站预约的车辆数 n_{rv}^o 之差是否等于0,以此判断当前用户在其原始的出发站有无车辆可用;类似地,式(7)要求将用户目的站空车位数 n_p^d ,与其他用户订单在目的站 d 已经预约的车位数 n_{rp}^d 和站点现有车辆数量 n_v^d 之和进行比较,若值大于1,则确保用户目的站有可用车位。根据系统站点实时状态,建议用户前往出发站 o 附近有可用车辆的重定位出发站 o' ,并从 o' 租车前往目的站,重定位过程中系统会为用户保留 o' 站车辆和目的站 d 车位,直至用户驾驶和归还车辆。

$$n_v^o - n_{rv}^o = 0 \quad (6)$$

式中: n_v^o 为用户出发站现有车辆数; n_{rv}^o 为系统已生成行程在站点 o 的预约车辆数。

$$n_p^d - n_{rp}^d - n_v^d > 1 \quad (7)$$

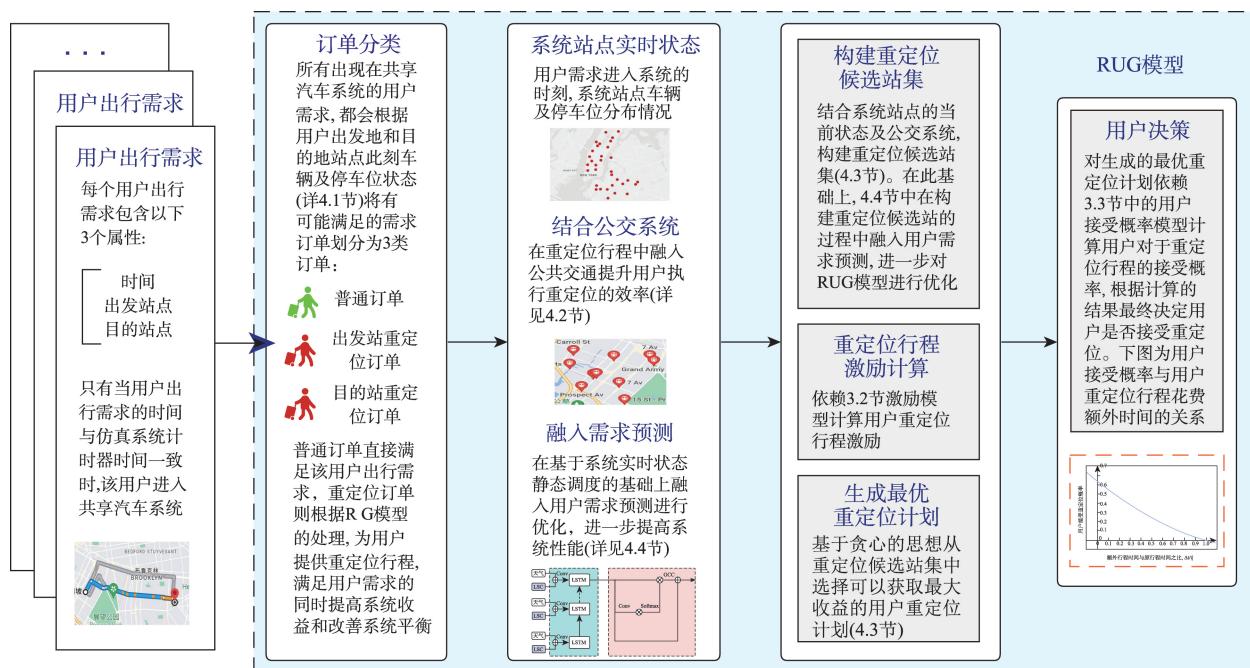


图3 RUG模型架构

Fig. 3 The architecture of RUG

式中: n_p^d 为用户目的站停车位数; n_{rp}^d 为站点 d 已预约车位数; n_v^d 为用户目的站现有车辆数。

(3) 目的站重定位(Destination Relocation, DR)订单。当出发站有可用车辆但目的站无可用车位, 即满足式(8)和式(9)时可执行目的站重定位, 其中式(8)判定出发站车辆数 n_v^o 减去该站点已预约车辆数 n_{rv}^o 是否大于1, 约束该行程出发站确保有可用车辆; 式(9)用于判断用户目的站是否无可用车位状态, 即用户目的站点 d 的车位数 n_p^d 减去该站所停车辆数 n_v^d 与被其他用户行程预约的车位数 n_{rp}^d 之和是否为0。根据系统站点实时状态, 建议用户将目的站 d 周围有可用车位的站 d' 作为重定位目的站, 重定位过程中系统会为用户保留站 d' 车位, 直至用户抵达并归还车辆。

$$n_v^o - n_{rv}^o > 1 \quad (8)$$

式中: 变量 n_v^o 与 n_{rv}^o 与式(6)中相同变量表示含义一致。

$$n_p^d - n_v^d - n_{rp}^d = 0 \quad (9)$$

式中: n_p^d 为用户目的站停车位数; n_v^d 为用户目的站现有车辆数; n_{rp}^d 为站点 d 已被预约停车位数。

站在用户角度, 若一次行程中同时采用重定位出发站和目的站, 会导致用户的服务体验糟糕, 故只考虑普通订单和上述2种重定位订单。

4.2 融入公共交通

重定位融入公共交通^[8]能提升系统弹性, 也有助最大化利用公共资源降低能耗与污染排放。鉴于共享汽车站点间距离通常远大于500 m(如纽约共享汽车 ZipCar^①的所有站点间最近距离约为1 200 m), 因此研究[8]设置的该距离约束会显著制约用户重定位订单的数量。为此, 本文放松500 m调度距离约束, 转而依据激励和用户接受概率模型, 向用户推荐时间代价最小(接受概率最高且收益最大)的重定位方式, 用户可以自行决定是否接受重定位, 并有权选择是否乘坐公交, 若乘坐则会由系统全额补贴公交费用, 具体示意如图1(d)和图1(e)。在将用户重定位融入公交系统后, 使用二元决策变量 u_j^i 表示用户重定位行程是否使用了公共交通, $u_j^i=1$ 表示使用公交, $u_j^i=0$ 表示不使用, 其中上标 i 和下标 j 分别表示用户重定位行程中使用公共交通的起始站。

4.3 收益驱动重定位

为保证系统收益, 制定了3项重定位准则, 即确保重定位不加剧系统不平衡度、最小化用户额外时间代价、不执行负利润重定位。其中, 不平衡度参考文献[6], 保证车站的可用车辆和车位数始终大于等于1, 对于加入需求预测的RUG模型, 不平衡度设置参见4.4节站点状态阈值; 后两项准则由式(11)和式(14)中大于0条件进行约束。

依据前景理论的确定效应, 模型针对普通订单, 确保其确定性收益。对于两类重定位订单, 若不调度则必然产生确定性损失, 此时转为依据前景理论的反射效应^[9], 即在面对损失风险时, 倾向于采取策略以期望损失减小或消失。换句话说, 将在用户是否同意调度的随机性上采用“赌一把”策略, 为用户提供替代性重定位行程建议, 若用户同意则确定损失转为收益, 同时可能降低系统不平衡度。

重定位决策以贪心方式从所有满足约束的重定位候选站中选取最大收益的站点, 并持续采用该方式应对随后的每一次重定位需求。

按照不加剧系统不平衡度准则, OR订单要求重定位出发站 o' 可用车辆至少2辆, 保证重定位后站 o' 仍有能力服务从 o' 出发的普通订单。候选站集 O_R 为所有具备出发站重定位条件的站点, 用式(10)表示。由于重定位收入和用户花费的额外时间负相关, 从候选站中选取收益最大的站点, 必能保证重定位最小化用户额外时间准则。式(11)表示结合激励和公交补贴确定 O_R 中局部收益最大的出发重定位站 o' 。令 p 为重定位到 o' 的用户接受概率, 根据式(1)和式(2), 容易理解 p 必为所有 O_R 站点中最大接受概率。OR订单按式(12)计算收益 i' , 其中 $p_{0,1}$ 表示用户根据接受概率模型随机产生的决策结果, 其值为1或0即表示用户接受或拒绝重定位。

$$O_R = \{i \in S | n_v^i - n_{rv}^i > 1 \wedge i \notin \{o, d\}\} \quad (10)$$

式中: n_v^i 为站 i 现有车辆数; n_{rv}^i 为站 i 的已预约车辆数; O_R 为满足出发重定位站约束的站点集合。

$$o' = \begin{cases} \arg \max \{r_d^o - l_d^i \times loss - \varepsilon - u_i^o \times \cos t_p\}, \\ i \in O_R \wedge \max \{r_d^o - l_d^i \times loss - \varepsilon - u_i^o \times \cos t_p\} > 0 \\ \emptyset, \quad \text{其他} \end{cases} \quad (11)$$

^① <https://www.zipcar.com/>。

式中: r_d^o 为用户原行程租金; l_i^o 为用户从重定位站 i 到目的站 d 的距离; $loss$ 为系统车辆行驶每公里的能耗和折旧成本; ε 为用户执行重定位, 系统给与的激励; u_o^o 为用户是否选择搭乘公共交通从出发站 o 前往重定位站 i ; $cost_p$ 为使用公共交通的补贴; O_R 为满足出发重定位站约束的站点集合; o' 为系统最终推荐的重定位出发站。式(12)变量 r_d^o 、 $loss$ 、 ε 、 $cost_p$ 与本式中变量含义一致, 不再赘述。

$$i' = (r_d^o - l_i^o \times loss - \varepsilon - u_o^o \times cost_p) \times p_{0,1} \quad (12)$$

式中: l_i^o 为用户从重定位出发站 o' 到目的站 d 的距离; u_o^o 为用户是否选择搭乘公共交通从出发站 o 前往重定位出发站 o' ; $p_{0,1}$ 为用户是否接受系统重定位; i' 为重定位行程收入。

与 OR 订单类似, DR 订单要求重定位目的站 d' 可用车位至少 2 个, 保证站 d' 作为重定位站后仍有能力服务目的站为 d' 的普通订单, 则具备目的站重定位条件的候选站集 D_R 可用式(13)表示。式(10)和式(13)确保重定位不加剧系统不平衡度。式(14)以收益最大原则计算重定位目的站 d' , DR 订单按式(15)计算收益。

$$D_R = \{i \in S | n_p^i - n_v^i - n_{rp}^i > 1 \wedge i \notin \{o, d\}\} \quad (13)$$

式中: n_v^o 为用户出发站的现有车辆数; n_{rp}^o 为系统已生成的出发站重定位行程在站点 o 的预约车辆数。

$$d' = \begin{cases} \arg \max \{r_d^o - l_i^o \times loss - \varepsilon - u_d^i \times cost_p\}, \\ i \in D_R \wedge \max \{r_d^o - l_i^o \times loss - \varepsilon - u_d^i \times cost_p\} > 0 \\ \emptyset, \text{ 其他} \end{cases} \quad (14)$$

式中: r_d^o 为用户原行程租金; l_i^o 为用户从出发站 o 到重定位站 i 的距离; $loss$ 为系统车辆行驶每公里的能耗和折旧成本; ε 为用户执行重定位, 系统给的激励; u_d^i 为用户是否选择搭乘公共交通从重定位目的站 i 前往目的站 d ; $cost_p$ 为公共交通补贴; D_R 为满足重定位目的站约束的站点集合; d' 为系统最终推荐的重定位目的站。

$$i' = (r_d^o - l_{d'}^o \times loss - \varepsilon - u_d^{d'} \times cost_p) \times p_{0,1} \quad (15)$$

式中: $l_{d'}^o$ 为用户从出发站 o 到重定位目的站 d' 的距离; $u_d^{d'}$ 为用户是否选择搭乘公交从重定位目的站 d' 前往目的站 d ; $p_{0,1}$ 为用户是否接受系统重定

位; i' 为重定位行程收入。其他变量如: r_d^o 、 $loss$ 、 ε 、 $cost_p$ 与式(14)中变量含义一致, 不再重复描述。

令所有普通订单总收入为 $\sum i$, OR 和 DR 两类重定位订单总收入为 $\sum i'$, 则总利润 P_R 可抽象为式(16), 其中 s_{rent} 为所有站点需缴纳的车位租金总和。

$$P_R = \sum i + \sum i' - s_{rent} \quad (16)$$

式中: i 和 i' 分别表示普通订单收入和重定位订单收入; s_{rent} 为系统运行期间所有站点需缴纳的车位租金总和; P_R 为系统总利润。

4.4 结合需求预测

仅考虑系统当前状态制定的重定位计划不具前瞻性, 加入用户出行预测能在制定搬迁计划时考虑到站点未来短期可能出发或到达的需求, 降低无效搬迁。本文基于 Liu 等^[11]提出的 CSTN 模型^②实现站点的出发到达需求预测。简而言之, CSTN(上下文空间-时间网络)由局部空间、时间演变和全局相关三部分上下文模块组成: 局部空间模块利用 2 个卷积神经网络分别学习出发点和目的地局部空间依赖性; 时间演变模块将局部空间特征和气象信息纳入卷积长短时记忆网络(ConvLSTM); 全局相关模块用于建立所有区域间的相关性。与 CSTN 模型预测范围内所有网格化区域间“出发-目的”稍有不同, 考虑到实际中共享汽车很难满足与站点距离过远的需求(如调度激励导致负收益、距离太远无法吸引用户等), 本文以纽约 ZipCar 真实站点方圆 500 m 范围构建区域, 基于区域间历史“出发地-目的地”订单样本训练 CSTN 网络(训练、验证和测试集合分别为一个月出行数据的前 17 d、中间 7 d 和后 7 d)。以 0.5 h 为时间窗, 输入过去 5 个时间段的订单来预测下一时间段各区域的出发和到达需求, 实际预测 MAE(平均绝对误差)为 0.53。

结合系统当前状态和未来半小时的需求预测结果来优化调度, 出发站候选站集 O_R 和到达站候选站集 O_D 的构建式(10)和式(13)分别调整为式(17)和式(18), 其中 $D^i - D_i$ 是站 i 未来半小时净需求, 即预测的出发需求 D^i 与到达需求 D_i 之差, 公式中符号含义与式(10)和式(13)一致。预测并非 100% 准确, 故用站点状态阈值进行约束(借鉴文献[10]的优先级策略, 将资源阈值设为 0.3 和 0.7), 通过站点预

^② 其他预测模型亦可; 此外, 根据第 5 节数据集中平均行程时长 28.5 min 设置半小时预测周期。

期车辆和容量之比衡量 O_R 中出发站车辆或 O_D 中目的站车位稀缺度, 避免重定位加剧系统不平衡。具体地, 用站点在该时间段的预期车辆数除以停车位容量计算该站车辆的稀缺程度(0~1 之间), 数值越大表示站点的车辆资源越充足。当该值大于阈值 0.3 时, 如式(17)条件, 认为站点当前车辆资源充足, 允许作为出发重定位候选站; 反之, 当该值小于阈值 0.7 时, 如式(18)条件, 认为站点车位资源充足, 允许作为目的重定位候选站。

$$\begin{aligned} O_R = \{i \in S | &n_v^i - n_{rv}^i > 1 \wedge (n_v^i + n_{rp}^i - (D^i - D_i)) \div n_p^i > \\ &0.3 \wedge i \notin \{o, d\}\} \end{aligned} \quad (17)$$

式中: i 和 S 分别代表系统站点及所有站点集合; n_v^i 和 n_{rv}^i 为站 i 现有车辆和被预约车辆数; n_{rp}^i 为站 i 已预约车位数; D^i 和 D_i 分别表示预测的站 i 出发需求与到达需求; n_p^i 为站 i 车位数; o 和 d 为用户出发站和目的站; O_R 为满足约束的出发重定位候选站集合。

$$\begin{aligned} O_D = \{i \in S | &n_p^i - n_v^i - n_{rp}^i > 1 \wedge (n_v^i + n_{rp}^i - (D^i - D_i)) \div \\ &n_p^i < 0.7 \wedge i \notin \{o, d\}\} \end{aligned} \quad (18)$$

式中: O_D 表示满足约束的目的重定位候选站集合。其他变量与式(17)中表示含义一致, 不再重复描述。

5 实验及结果分析

5.1 实验对比方案及设置

为验证提出模型的有效性, 评估对比以下 7 个方案(均在同平台用 Python 实现), 其中前 3 个方案作为基线与本文提出的 RUG 模型进行性能对比评

估, 用与评估模型的性能; 后 3 个方案在 5.2.3 节中进行消融实验, 用于分析公共交通和需求预测对模型的影响:

(1) 基线: 基于运营商的调度模型 OVOS^[10]。

(2) GA-ap: 借鉴遗传算法思想改进并利用启发式方法求解运营商重定位模型^[5]近似最优解。具体地, 按每时段 2 小时将一天分为 12 个时段, 计算站点当前时段预期净车辆数 $n_v^i - D^i + D_i$, n_v^i 、 D^i 和 D_i 分别表示 i 站车辆数、根据历史订单得到的预期出发和到达需求, 根据式(19)和式(20)分别构建空站集(车辆供小于求且可用车辆大于 0)和满站集(车辆供大于求且可用车位大于 0), 并按站点 i 预期净车辆数分别编码基因。基因序列优化采用贪心方法, 每次运营商调度车辆(从满站向空站)选择成本最低路线, 通过交换迭代基因直至满站集或空站集基因均为 0 时达到近似最优。过程如图 4 所示, 图中上方和下方分别为满站集和空站集的基因编码, 每次基因交换选择满站集到空站集时间最短(即代价最小)基因进行交换(对应满站基因 -1, 空站基因+1)并执行调度, 重复该过程直至满站或空站基因为全 0 时终止。

$$\text{满站集} = \{i \in S | n_v^i - D^i + D_i > 0 \wedge n_v^i > 0\} \quad (19)$$

式中: i 和 S 分别代表系统站点及所有站点集合; n_v^i 为站 i 现有车辆数; D^i 和 D_i 分别表示预测的站 i 出发需求与到达需求数。

$$\text{空站集} = \{i \in S | n_v^i - D^i + D_i < 0 \wedge n_p^i - n_v^i - n_{rp}^i > 0\} \quad (20)$$

式中: i 、 S 、 D^i 、 D_i 、 n_v^i 与式(19)中代表含义相同, n_p^i 和 n_{rp}^i 则分别表示站 i 停车位和已预约停车位数。

(3) URIS: 基于用户的重定位模型^[6], 以系统站点平衡性为优化目标。URIS 结合历史订单得出预

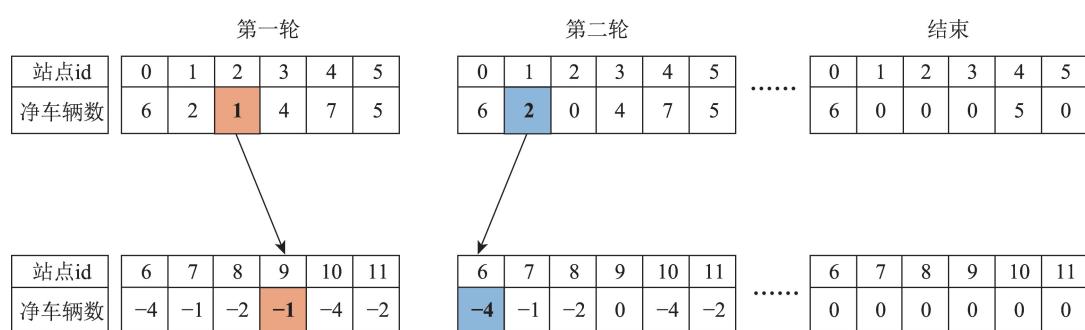


图 4 遗传基因交换示意图

Fig. 4 An example of gene exchange

期需求(详见4.2节),然后根据式(21)计算站点当前时段的不平衡阈值 T^s 。站点供需状态由式(22)确定,不满足该条件则为不平衡站。当存在多个不平衡站时,模型优先选择距离用户目的站最近的站作为重定位站。为避免使用不同用户激励计算对实验结果产生影响,激励均采用本文的式(1)计算。为避免主观因素公平对比,用户接受概率均采用公式(2)模型计算。为更公平地与RUG相比,本文在URIS模型中也融入了公共交通系统,用户重定位可选择是否使用公共交通,若使用费用同样由运营商承担。

$$T^s = \frac{B^s \times v_{tl,2}}{B} \quad (21)$$

式中: T^s 为站点 s 当前时段的不平衡阈值; B^s 、 $v_{tl,2}$ 和 B 分别表示当前时段 s 站预期需求、可用车辆数及系统总预期需求。

$$T^s \leq ci^s + ct^s \quad (22)$$

式中: T^s 为 s 站此时段不平衡阈值; ci^s 和 ct^s 分别表示 s 站现有和预期到达的车辆数。

(4)RUG:本文提出的RUG模型。

(5)URIS-NoPub:不含公共交通的URIS模型,即采用式(1)激励计算的文献[6]模型。

(6)RUG-NoPre:不含出行需求预测的RUG模型。

(7)RUG-NoPub:不含公共交通的RUG模型。

实验基于纽约真实出租车出行数据^③,模拟环境将一周内15 024个用户需求逐条按顺序实时输入各模型系统,记录服务和重定位的订单数、系统运营成本和最终收益等。采用纽约往返型共享汽车ZipCar的33个站点位置(站点间平均步行及公交时间分别为74 min和35 min)和租金标准(约\$0.3/min)。单向共享汽车需要调度,通常单价更高,故增加\$0.4和\$0.5两个价格作为对比。ZipCar共419个车位中,纽约政府免费提供其中228个^④,故实验中车位价格采用3种情况讨论,即政府全提供(\$0)、政府不提供(\$570,依据纽约月均停车位费用^⑤)和部

分政府提供(\$285,即\$570一半)。站间行驶时间用HERE地图^⑥获得,每次乘坐公交\$3。电动汽车损耗^⑦约\$0.003 7/km,忽略对结果影响很小的电池限制^⑧。ZipCar调度员时薪\$16.5作为标准^⑨。无特别说明,实验默认使用\$285车位费用和\$0.4/分钟车辆租金。

OVOS按站点阈值优先级确定重定位行程,优先级相同则时间短优先(详见3.1节)。图5展示OVOS不同调度员数量的利润,后续实验将以性能最优的3个员工为默认值。

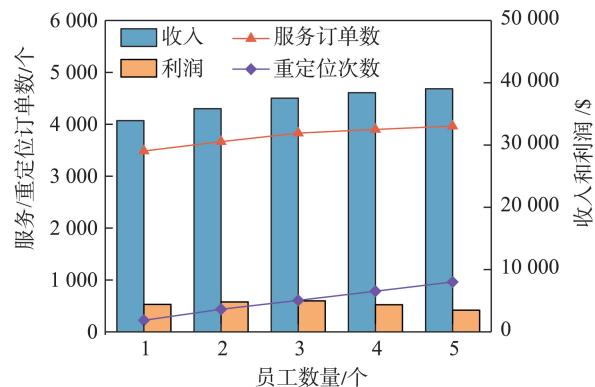


图5 OVOS员工数量影响

Fig. 5 Effect of the number of OVOS employee

5.2 实验结果

5.2.1 性能对比

本节从服务订单提升率 $R_o = \frac{O_R - O_B}{O_B}$ 、收入增加率 $R_i = \frac{i_R - i_B}{i_B}$ 和利润增加率 $R_p = \frac{P_R - P_B}{P_B}$ 3个方面对比各方法的性能差异,其中 O_R 和 O_B 表示对比方案和基线的服务订单数, i_R 和 i_B 表示对比方案和基线的收入, P_R 和 P_B 表示对比方案和基线的利润。

如表1所示,融入预测的用户调度模型RUG比运营商调度模型OVOS和GA-ap订单数分别提升94%和114%,收入提升了74%和92%,净利润提高6.5倍和7.0倍,其原因主要是基于运营商的调度需要支付员工薪水,导致收益下降严重。从实验结果

^③ <https://learn.microsoft.com/zh-cn/azure/open-datasets/dataset-catalog>。

^④ <https://avispbudgetgroup.com/zipcar-and-the-city-of-new-york-announce-two-major-initiatives-to-reduce-personal-car-ownership-and-increase-access-to-car-sharing/>。

^⑤ <https://monthlyparking.org/nyc-monthly-parking>。

^⑥ <https://www.here.com/platform/here-sdk>。

^⑦ <https://www.fleetforward.com/10137843/electric-models-depreciation-still-drags-down-ownership-costs>。

^⑧ <https://www.indeed.com/cmp/Zipcar/salaries/Dispatcher>。

表1 不同方法的性能对比

Tab. 1 Performance comparison between different methods

	服务订单数/个	收入/\$	利润/\$	重定位次数/次	$R_o/\%$	$R_i/\%$	$R_p/\%$
OVOS	3 831	37 516	4 985	—	—	—	—
GA-ap	3 469	34 007	4 683	—	-9	-9	-6
URIS	6 495	51 589	23 516	3 022	70	38	372
RUG	7 458	65 481	37 399	2 807	95	75	650

注:加粗数值表示本文提出模型RUG的实验性能及对比结果。

看,同为基于用户重定位且加入公交系统的URIS相比RUG性能差距明显,RUG比前者的订单和收入分别提升14%和26%,净利润提高0.6倍。主要存在2个方面原因:①URIS目标是尽可能通过重定位降低系统不平衡度,而非提高最大收益,这意味着URIS的决策约束相比同时考虑平衡和收益的RUG更为宽松,导致可能将普通订单指派执行重定位以保证平衡性,从而损失收益,而RUG则是当资源无法满足时才考虑重定位,在采取贪心策略保证最大额外收益的同时降低系统不平衡性;②URIS仅支持目的站重定位,而RUG同时支持出发站和目的站重定位,使重定位范围更广,能获得的潜在订单数更多。

5.2.2 时段影响

图6展示了不同时段对方法性能的影响。相比其他方法,RUG在非高峰期/高峰时段的单位距离收益高出约15%~20%,尤其早高峰期盈利能力提升更显著,充分说明不考虑时段因素会限制整体收益。相比基线方法,基于运营商调度的OVOS和GA-ap确实提高了非高峰期效益,但并未给高峰期带来质的影响。一方面,调度员工的数量会限制高峰期维持系统平衡度的效果;另一方面,由于调度

需要花费时间,可能因此错过较多用户订单。URIS效果不理想的原因在于,交通高峰期是典型的资源不平衡状态,收入中很大一部分都用于填补用户激励。RUG-NoPub由于未纳入公交系统,其实验结果更具参考意义。相比RUG,RUG-NoPub由于重定位用户激励大幅提升且重定位范围收缩,导致收益下滑;而相比其他重定位方法,若不结合公交系统,采用用户花费额外时间的用户接受概率和激励策略,会使得非高峰期订单数量和利润降低。

5.2.3 消融实验

为了验证融入公交和需求预测对RUG及URIS性能的影响,表2展示了针对这2个方面的消融实验。

与表1情况类似,无公共交通的URIS-NoPub性能同样不如去除公共交通的RUG-NoPub,二者在订单数和收入接近的情况下(RUG-NoPub仅提升2%和4%),利润却相差34%,说明RUG模型具有更强的盈利能力,其主要原因是RUG和URIS分别以最大收益和系统最佳平衡为目标进行调度。另外,通过观察二者的重定位情况发现,URIS-NoPub将原本可以带来收益的普通订单设定成重定位订单,这也是URIS-NoPub盈利不及RUG-NoPub的重要原因。值得一提的是,RUG比URIS-NoPub利润提升近5倍。

RUG-NoPub在服务订单数、收益和利润方面仅能达到RUG的47%、51%和15%,这表明融入公交系统对提高RUG模型的性能至关重要。原因有:①结合公交能大大降低用户重定位的额外时间(见5.1节),从而降低用户激励成本提升系统收益;

表2 模型消融实验

Tab. 2 Ablation Experiments

	服务订单数/个	收入/\$	利润/\$	重定位次数/次
URIS-NoPub	3 442	32 112	4 122	1 490
RUG-NoPub	3 512	33 544	5 550	229
RUG-NoPre	7 136	63 554	35 480	2 822
RUG	7 458	65 481	37 399	2 807

注:加粗数值表示本文提出模型RUG的实验结果。

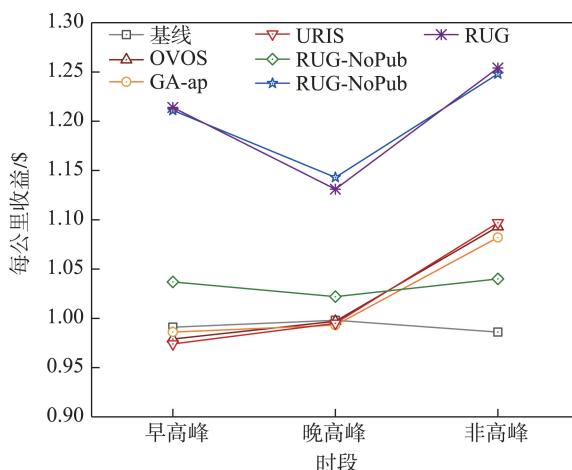


图6 不同时段对性能的影响

Fig. 6 Effect of different time periods

②结合公交能使原本用户步行无法执行的重定位成为可能,增加系统收入。

相较于未添加需求预测的RUG-NoPre, RUG的订单、收入和利润分别增加了4.5%、3%和5.4%,说明融入需求预测对提高模型性能起到积极作用。注意到融入需求预测后,RUG执行的用户重定位次数比RUG-NoPre更少,但服务的总订单数却提高了4.5%,说明结合需求预测制定用户重定位计划更有前瞻性,在提高收益的同时也提升了系统的平衡性和用户服务水平。

鉴于RUG相比基于运营商模型OVOS和GA-ap以及基于用户重定位方法URIS性能更理想,接下来的实验将着重讨论RUG模型参数的影响。

5.2.4 额外时间影响

本节探索用户重定位花费额外时间的影响。将额外时间与原行程时间比值范围(0,1/3)、[1/3,2/3]和[2/3,1)定义为短时、中时和长时。如表3所示,重定位订单主要集中在短时额外时间,且平均收入明显较高,长时额外时间则相反。这与用户激励和接受概率分别与重定位付出额外时间成正比和负相关的逻辑相符。这一结论也暗示,共享汽车系统热点需求区域站点间距离不宜相隔太远,以利于同时提高需求满足程度和收益。

5.2.5 用户可接受额外时间上限约束

Boyaci^[13]通过对真实共享汽车用户调研得出用户对重定位的接受度与用户花费额外时间相关。为了验证用户额外花费时间对RUG性能的影响,本节设置用户接受重定位额外时间上限进行实验。如表4所示,设置可接受额外时间上限确实会一定程度降低RUG收益,当用户接受最大额外时

表3 额外时间影响

Tab. 3 Effect of extra time cost

	额外时间	重定位 订单数/个	重定位 订单收入/\$	平均收入/\$
RUG-NoPub	短	46	437	9.50
	中	139	731	5.25
	长	44	126	2.86
RUG-NoPre	短	2 077	18 293	8.80
	中	725	2 814	3.88
	长	32	24	0.75
RUG	短	1 825	16 203	8.88
	中	944	3 725	3.95
	长	38	31	0.82

注:加粗数值表示3个模型在不同额外时间下重定位订单数、重定位订单收入及平均收入3个维度对比最好的结果。

表4 用户可接受的额外时间上限约束的影响

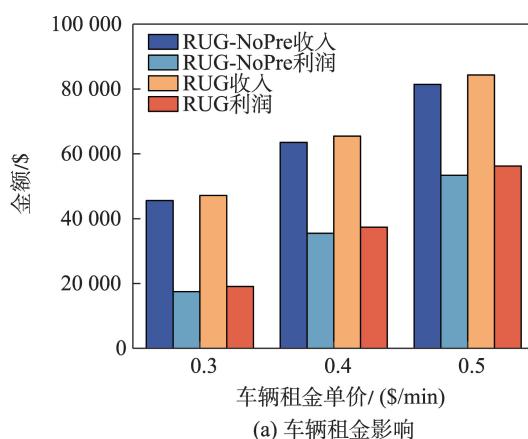
Tab.4 Effect of extra time toplimit acceptable to users

额外时间占比/%	服务订单数/个	收入/\$	利润/\$
10	4 424	43 520	15 510
30	6 014	57 350	29 297
50	7 027	63 708	35 636
70	7 164	64 081	36 004

间比例为10%和30%时,系统收益为无时间上限约束的41%和78%,基本能够体现RUG对耐心较差用户的容错性;而当额外时间上限大于等于原行程50%,系统收益已接近无时间约束(95%),说明RUG模型具有很好的用户可用性。

5.2.6 租金影响

图7(a)和图7(b)分别展示改变车辆租金单价和



(a) 车辆租金影响

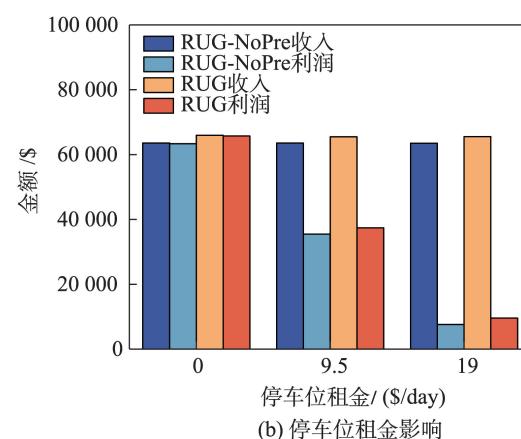


图7 车辆租金单价和车位价格的影响

Fig. 7 Effect of vehicle rental & parking prices

车位价格所带来的收益变化趋势。当车辆租金单价提升时,收入和利润均稳步增长,而车位租金价格提升时,收入没有发生变化,利润下滑明显。以上现象说明基础设施的投入成本以及租车费用的设置对整个系统的运营利润影响较大,应当慎重设置。

6 结论

本文提出一种收益驱动的单向共享汽车用户重定位模型RUG,解决现有方法难以有效提升共享汽车企业盈利能力的问题。相比现有基于用户重定位方法,RUG模型通过结合公共交通提高用户重定位弹性,融入出行需求预测提升重定位方案的平衡性。

(1)本文以前景理论为理论基础提出RUG模型,一方面以确定效应保证当前普通订单收益,另一方面依据反射效应,采取用户激励吸引用户接受重定位行程建议,能够将部分原本无法满足的需求损失转为收益,同时降低系统不平衡度。

(2)在真实数据集上的实验证明,用户重定位模式比基于运营商调度性能优势显著;相比现有基于用户调度的URIS方法,在用户激励和接受概率模型相同的条件下,RUG模型在订单量、收益等方面优势同样明显,分别能提高14%和60%,且考虑时间代价的激励模型能显著提升交通高峰期的收益能力。

(3)消融实验说明公交系统的融入对于RUG模型至关重要,而结合预测不仅能为RUG模型提升5.4%的净收益,同时还能提高用户服务水平(表2中RUG比RUG-NoPre增加了4.5%服务订单数)、改善系统不平衡性(表2中RUG比RUG-NoPre重定位行程数量更少)。

(4)通过5.2.4节额外时间影响的实验数据可以发现,热点需求区域共享汽车站点间距离不宜相隔太远,有助于同时提高需求满足程度和收益。

综上所述,本文提出的模型从理论和实验2个方面均展示了其合理性和有效性,能够对共享汽车的运营收益提升有所帮助。

参考文献(References):

[1] Nijland H, van Meerkirk J. Mobility and environmental impacts of car sharing in the Netherlands[J]. Environmental

Irrigation and Societal Transitions, 2017,23:84-91.
DOI:10.1016/j.eist.2017.02.001

[2] Duncan M. The cost saving potential of carsharing in a US context[J]. Transportation, 2011,38(2):363-382. DOI:10.1007/s11116-010-9304-y

[3] Dong X L, Cai Y F, Cheng J M, et al. Understanding the competitive advantages of car sharing from the travel-cost perspective[J]. International Journal of Environmental Research and Public Health, 2020,17(13):4666. DOI:10.3390/ijerph17134666

[4] Ciari F, Bock B, Balmer M. Modeling Station-based and free-floating carsharing demand[J]. Transportation Research Record: Journal of the Transportation Research Board, 2014,2416(1):37-47. DOI:10.3141/2416-05

[5] Nair R, Miller-Hooks E. Fleet management for vehicle sharing operations[J]. Transportation Science, 2011,45(4):524-540. DOI:10.1287/trsc.1100.0347

[6] Brendel A B, Brauer B, Hildebrandt B. Toward user-based relocation information systems in station-based one-way car sharing[C]. Twenty-second Americas Conference on Information Systems, 2016.

[7] Wang N, Jia S L, Liu Q Q. A user-based relocation model for one-way electric carsharing system based on micro demand prediction and multi-objective optimization[J]. Journal of Cleaner Production, 2021,296:126485. DOI:10.1016/j.jclepro.2021.126485

[8] Stokkink P, Geroliminis N. Predictive user-based relocation through incentives in one-way car-sharing systems [J]. Transportation Research Part B: Methodological, 2021,149:230-249. DOI:10.1016/j.trb.2021.05.008

[9] Kahneman D, Tversky A. Prospect theory: An analysis of decision under risk[J]. Econometrica, 1979,47(2):263. DOI:10.2307/1914185

[10] Repoux M, Kaspi M, Boyaci B, et al. Dynamic prediction-based relocation policies in one-way station-based carsharing systems with complete journey reservations[J]. Transportation Research Part B: Methodological, 2019, 130:82-104. DOI:10.1016/j.trb.2019.10.004

[11] Liu L B, Qiu Z L, Li G B, et al. Contextualized spatial-temporal network for taxi origin-destination demand prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2019,20(10):3875-3887. DOI:10.1109/TITS.2019.2915525

[12] Boyaci B, Zografos K, Geroliminis N. An optimization framework for the development of efficient one-way carsharing systems[J]. European Journal of Operational Re-

- search, 2015,240(3):718- 733. DOI:10.1016/j.ejor.2014.07.020
- [13] Herrmann S, Schulte F, Voß S. Increasing acceptance of free-flooding car sharing systems using smart relocation strategies: A survey based study of car2go hamburg[C]// Lecture Notes in Computer Science. Chile: Springer International Publishing, 2014:151- 162. DOI:10.1007/978-3-319-11421-7_10
- [14] Cepolina E M, Farina A, Pratelli A. Car-sharing relocation strategies: a state of the art[M]// Public Mobility Systems. Southampton: WIT Press, 2014:109-120. DOI:10.2495/978-1-84564-908-1/010
- [15] Kek A G H, Cheu R L, Chor M L. Relocation simulation model for multiple-station shared-use vehicle systems[J]. Transportation Research Record: Journal of the Transportation Research Board, 2006,1986(1):81- 88. DOI:10.1177/0361198106198600111
- [16] Kek A, Cheu R, Meng Q, et al. A decision support system for vehicle relocation operations in carsharing systems[J]. Transportation Research Part E: Logistics and Transportation Review, 2009,45(1):149- 158. DOI:10.1016/j.tre.2008.02.008
- [17] Brendel A B , Brennecke J T , Kolbe L. Applying econophysics in the context of carsharing-development of a vehicle relocation algorithm and decision support system [C]//Proceedings of the International Conference on Information Systems 2018. San Francisco:ICIS, 2018.
- [18] Kypriadis D, Pantziou G, Konstantopoulos C, et al. Optimizing relocation cost in free-flooding car-sharing systems [J]. IEEE Transactions on Intelligent Transportation Systems, 2020,21(9):4017- 4030. DOI:10.1109/TITS.2020.2995197
- [19] Gambella C, Malaguti E, Masini F, et al. Optimizing relocation operations in electric car-sharing[J]. Omega, 2018, 81:234-245. DOI:10.1016/j.omega.2017.11.007
- [20] Yang S, Wu J J, Sun H J, et al. Double-balanced relocation optimization of one-way car-sharing system with real-time requests[J]. Transportation Research Part C: Emerging Technologies, 2021,125:103071. DOI:10.1016/j.trc.2021.103071
- [21] Wagner S, Willing C, Brandt T, et al. Data analytics for location-based services: enabling user-based relocation of carsharing vehicles[C]. International Conference on Information Systems. 2015. DOI:10.13140/RG.2.1.1595.6966
- [22] Schulte F, Voss S. Decision support for environmental-friendly vehicle relocations in free-flooding car sharing systems: The case of Car2go[J]. Procedia CIRP, 2015,30: 275-280. DOI:10.1016/j.procir.2015.02.090
- [23] Brandstätter G, Kahr M, Leitner M. Determining optimal locations for charging stations of electric car-sharing systems under stochastic demand[J]. Transportation Research Part B: Methodological, 2017,104:17- 35. DOI:10.1016/j.trb.2017.06.009
- [24] Wang N, Liu Q Q, Guo J H, et al. A user-based adaptive joint relocation model combining electric car-sharing and bicycle-sharing[J]. Transportmetrica B: Transport Dynamics, 2022,10(1):1046- 1069. DOI:10.1080/21680566.2021.2007174
- [25] Barberis N C. Thirty years of prospect theory in economics: A review and assessment[J]. Journal of Economic Perspectives, 2013,27(1):173-196. DOI:10.1257/jep.27.1.173
- [26] Yuan Q, Cong G, Ma Z Y, et al. Time-aware point-of-interest recommendation[C]// Proceedings of the 36th international ACM SIGIR conference on Research and development in information retrieval, New York:ACM.2013, 363-372. DOI:10.1145/2484028.2484030